淘宝数据魔方的系统架构

殷琳君（长林）

淘宝网

互联网公司技术架构系列资料

由  为您悉心整理

快简历

KuaiJianLi.com

/* 让工作重新关于成长和成就、关于快乐和分享、关于梦想和荣光 */

Agenda

- 数据产品总体架构
- 分布式MySQL集群
- NoSQL存储与计算
- 统一的数据中间层
- 通用数据报表框架

每天的数据

- 淘宝主站：
  - 30亿店铺、宝贝浏览
  - 千万量级交易笔数
- 数据产品：
  - 60G统计汇总结果
  - 千万量级数据查询请求

海量数据带来的挑战

- 计算
- 存储
- 读写

架构总览

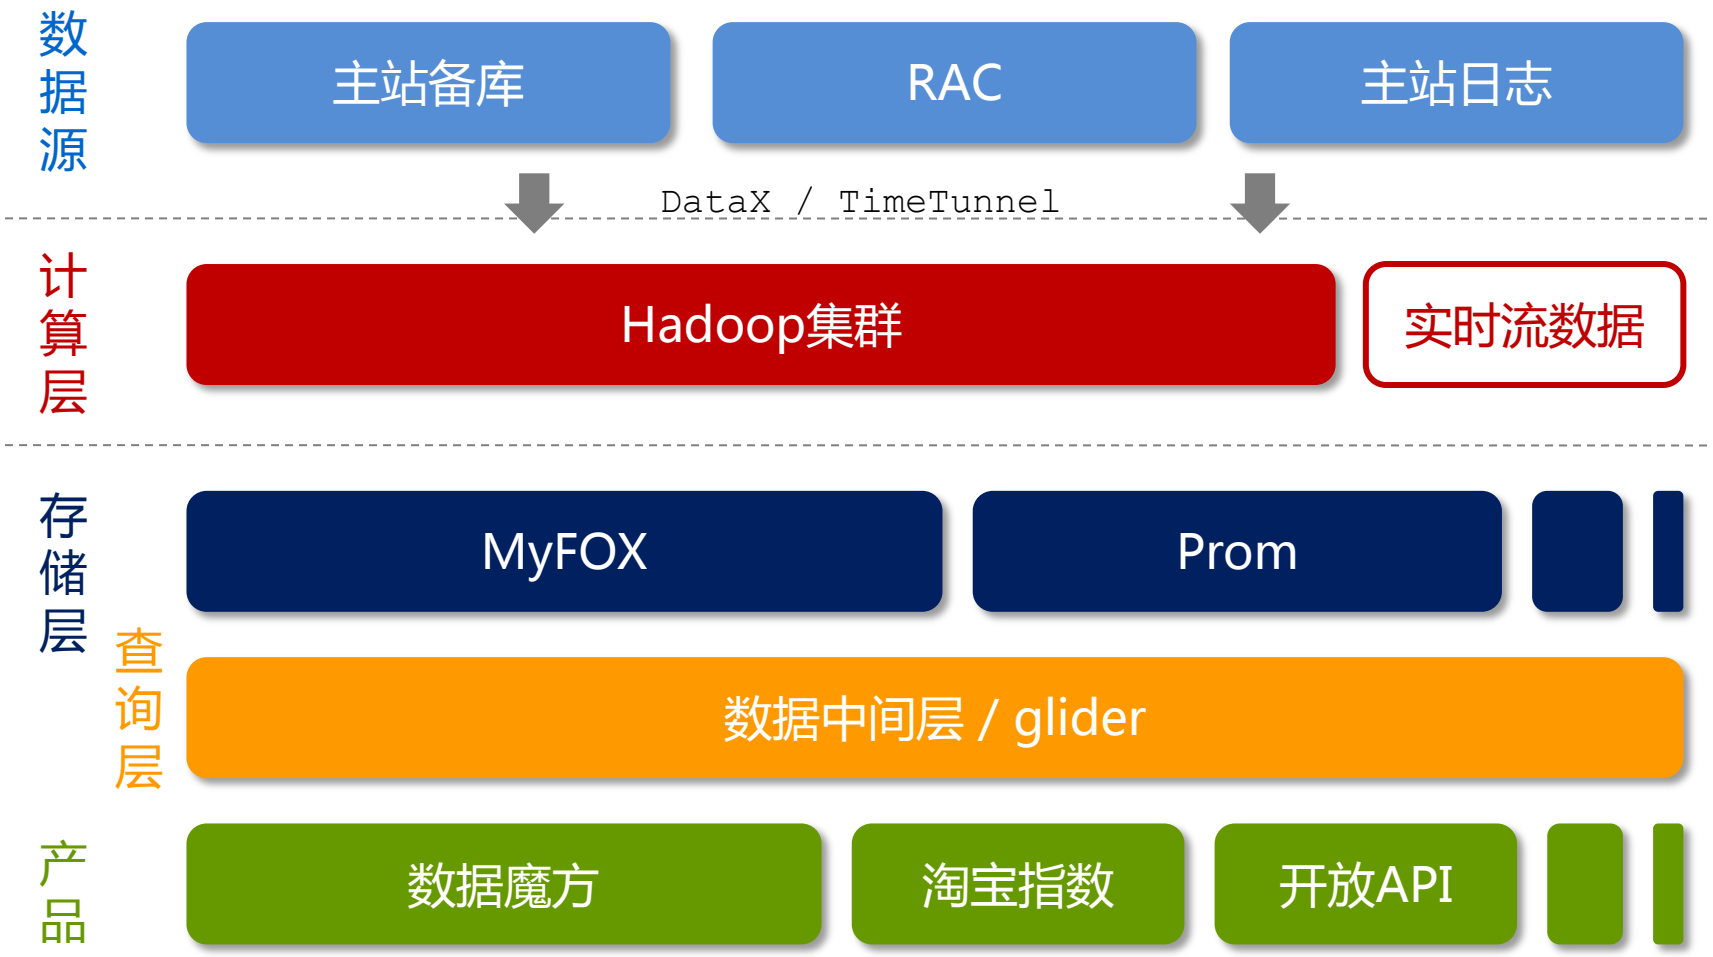
数据源
主站备库
RAC
主站日志
DataX / TimeTunnel
计算层
Hadoop集群
实时流数据
存储层
MyFOX
Prom
查询层
数据中间层 / glider
产品
数据魔方
淘宝指数
开放API

分布式MySQL集群—MyFOX

需求：

- SQL查询
- 海量存储
- 可横向扩展
- 对应用透明
- 兼顾性能

分布式MySQL集群—MyFOX

- 分库分表
  - 基于业务特点
- 透明的中间层（MyFOX）
  - 查询代理
  - 数据装载
  - 集群管理

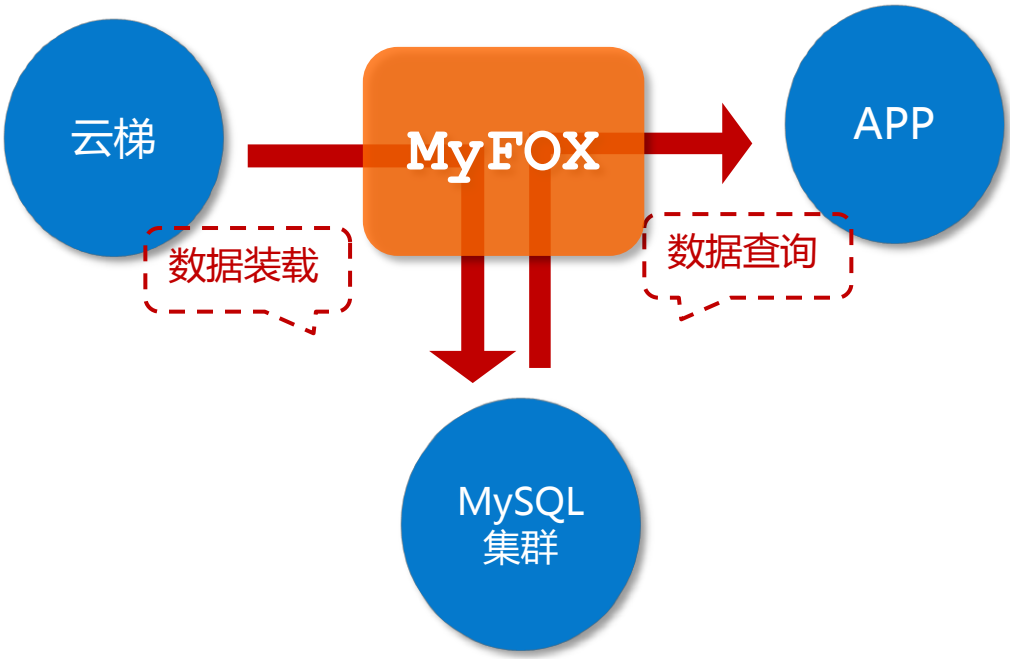

MyFOX—分片规则

- 冗余复制
  - 小表
  - 访问频繁
  - JOIN
- 条目切割
  - 按路由字段的值，每N行切片
  - 路由字段是一级索引
  - 分散压力、并行查询

示例：条目切割

- 切片
  - 阈值（200W）
  - 上浮动（5%）
- 装桶
  - 一个桶装满再开新桶
  - “桶”即实际的物理表

thedate=20100816, tid=11^A2090000
thedate=20100816, tid=12^A2120000
thedate=20100816, tid=13^A760000
thedate=20100816, tid=14^A289

thedate=20100816, tid=11^A2090000
thedate=20100816, tid=12^A2000000
thedate=20100816, tid=12^A120000
thedate=20100816, tid=13^A760000
thedate=20100816, tid=14^A289

thedate=20100816, tid=11^A2090000
thedate=20100816, tid=14^A289

thedate=20100816, tid=12^A2000000

thedate=20100816, tid=13^A760000
thedate=20100816, tid=12^A120000

MyFOX—数据查询

```
SELECT IF(INSTR(f.keyword,' ') > 0, UPPER(TRIM(f.keyword)),
    CONCAT(b.brand_name,' ',UPPER(TRIM(f.keyword)))) AS f0,
    SUM(f.search_num) AS f1,
    SUM(f.uv) AS f2,
    ROUND(SUM(f.search_num) / SUM(f.uv), 2) AS f3,
    AVG(f.uv) AS f4
FROM f
INNER JOIN dim_brand b ON f.keyword_brand_id = b.brand_id
WHERE f.keyword_type_id = 1 AND f.keyword != ''
    AND keyword_cat_id IN ('50002535')
    AND thedate <= '2011-03-10'
    AND thedate >= '2011-03-08'
GROUP BY f0
ORDER BY SUM(f.search_num) DESC LIMIT 0, 1500
```

MyFOX—数据查询

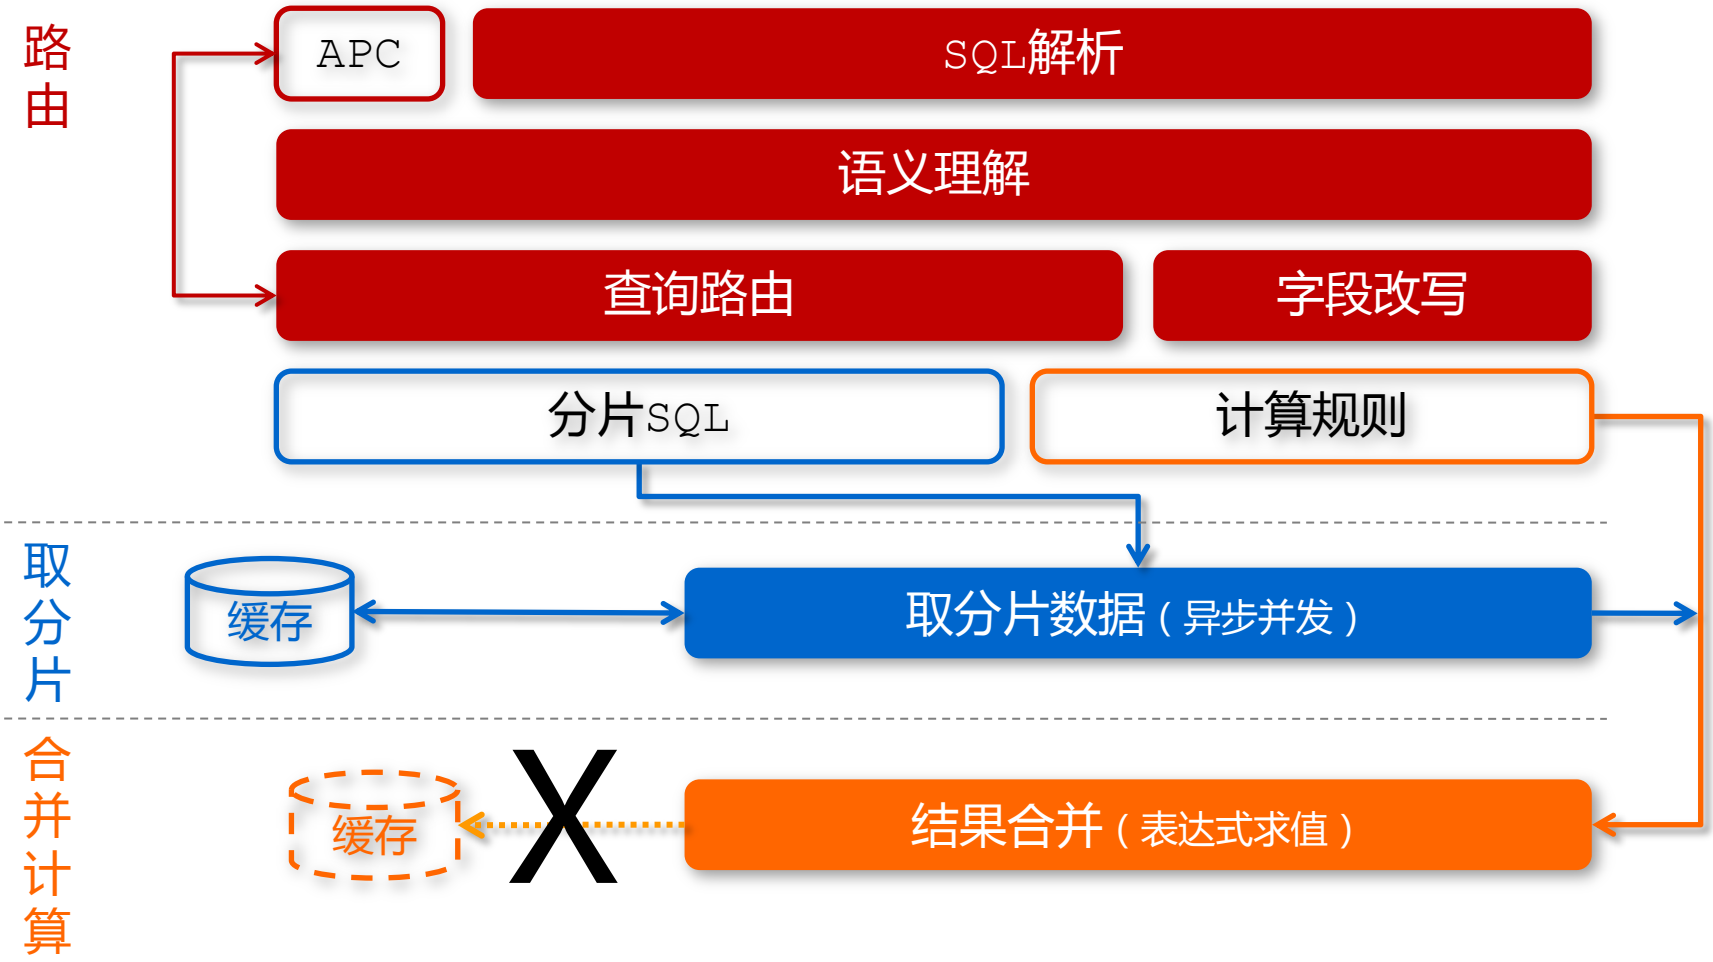
路由
APC
SQL解析
语义理解
查询路由
字段改写
分片SQL
计算规则
取分片
缓存
取分片数据（异步并发）
合并计算
缓存
X
结果合并（表达式求值）

MyFOX路由层—语义理解

```
WHERE thedate <= '2011-03-10'
  AND thedate > '2011-03-07'
  AND toprank_id IN (2, 3)
```

	2	3
2011-03-08	{"toprank_id":"2", "thedate":"2011-03-08"}	{"toprank_id":"3", "thedate":"2011-03-08"}
2011-03-09	{"toprank_id":"2", "thedate":"2011-03-09"}	{"toprank_id":"3", "thedate":"2011-03-09"}
2011-03-10	{"toprank_id":"2", "thedate":"2011-03-10"}	{"toprank_id":"3", "thedate":"2011-03-10"}

MyFOX路由层—字段改写

```
SELECT a AS f0,
   SUM(f.search_num) AS f1,
   SUM(f.uv) AS f2,
  ROUND(SUM(f.search_num) / SUM(f.uv), 2) AS f3,
   AVG(f.uv) AS f4
```

- AVG (a)
- 1 + SUM(a)
- SELECT a FROM ... ORDER BY b
- 重复查询列

MyFOX缓存

- 缓存哪部分数据？
  - 最终结果
  - 分片数据

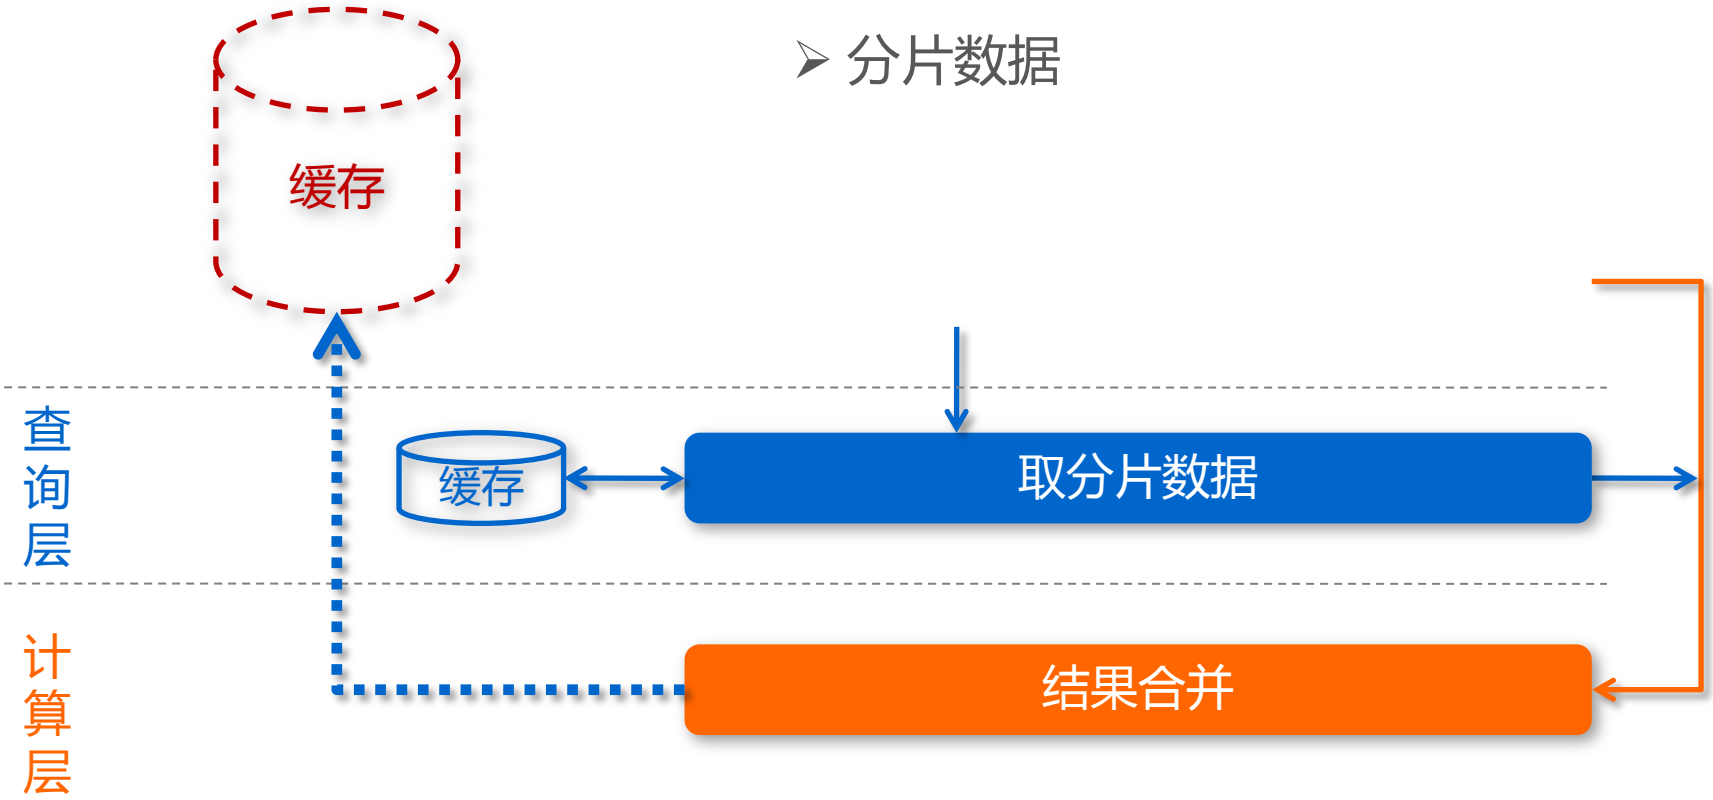

MyFOX—数据装载

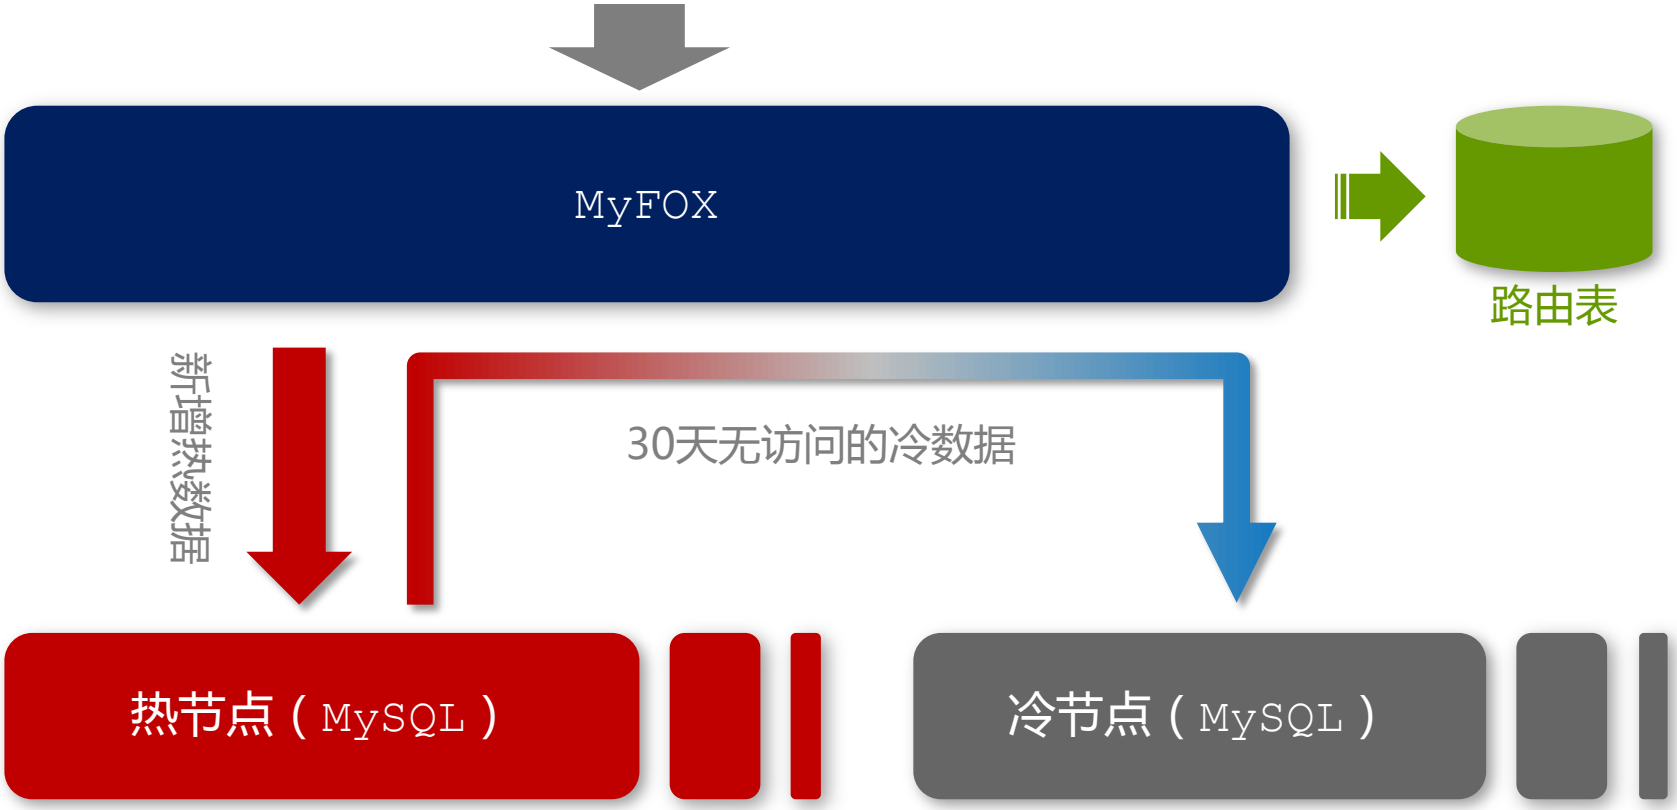

15k SAS盘，300G * 12，raid10
成本:4.5W / T

7.2k SATA盘，1T * 12，raid10
成本:1.6W / T

这个问题能解决吗


查询条件
所有分类 > 笔记本电脑
查看
取消
品牌
输入您要查询的品牌
**热门品牌*展示该类目下50个热销品牌，您可以在搜索框中查询全部品牌
热门品牌： ThinkPad Apple/苹果 Lenovo/联想 Asus/华硕 Dell/戴尔 Acer/宏基 HP/惠普 other/其它 Samsung/三星
*属性选择目前可查看最近7天内的数据
笔记本尺寸： 11寸 5寸 7寸 8寸 9寸 10寸 12寸 13寸 14寸 15寸
笔记本定位： 商务定位 便携定位 家庭影音 女性定位 学生定位 游戏娱乐 迷你定位 入门定位
硬盘容量： 20G 30G 40G 60G 80G 40G以下 120G 160G 200G 10G
重量： 1公斤以下 1-1.5公斤 1.5-2公斤 2-2.5公斤 2.5公斤以上
颜色分类： 透明 花色 褐色 白色 黄色 红色 酒红色 紫色 浅灰色 绿色
蓝牙功能： 无 有
指纹功能： 无 有
迅盘技术： 无 有
显卡显存容量： 3G 950M 共享内存容量 256M 512M 128M 64M 1G 32M以下 32M
内存容量： 3G 32G 256M 512M 128M 64M 64M以下 1G 4G 2G
笔记本CPU： 酷睿四核 酷睿2至尊 奔腾M(Dothan) 奔腾双核 炫龙64 X2 移动奔腾3 奔腾4 苹果G4 苹果G3 速龙64

Prom—应用场景

- 数据量很大
- 无法穷举所有可能的查询条件组合
- 大量穷举出来的条件组合无意义

Prom—算法

13寸、商务定位的笔记本昨天的交易金额是多少？

1、查询13寸笔记本昨天的交易ID
2、查询商务定位笔记本昨天的交易ID
3、求交易ID交集
4、根据3中的交易ID查询明细数据，按照金额进行汇总

Prom—第一版Redis

- Redis
  - Key-Value的内存数据库
  - 支持List、Set等数据结构
- 瓶颈
  - 大量随机读取明细
  - 内存受限，数据持久化问题

Prom—第二版HBase

- 定制化的存储
  - HBase建立在hdfs之上，和Hadoop无缝集成
  - 可水平扩展
- 实时计算
  - 百万记录

Prom—HBase表设计

Row-key	列族1 （交易ID，索引）	列族2 （交易明细）
笔记本尺寸：13寸	1，2，4，9	{58, 600,35}, {72,999,14}, {92,103,77}, {36,702,101}
笔记本定位：商务定位	1，4，7	{58, 600,35}, {92,103,77}, {85, 442, 152}

Prom—HBase实时计算

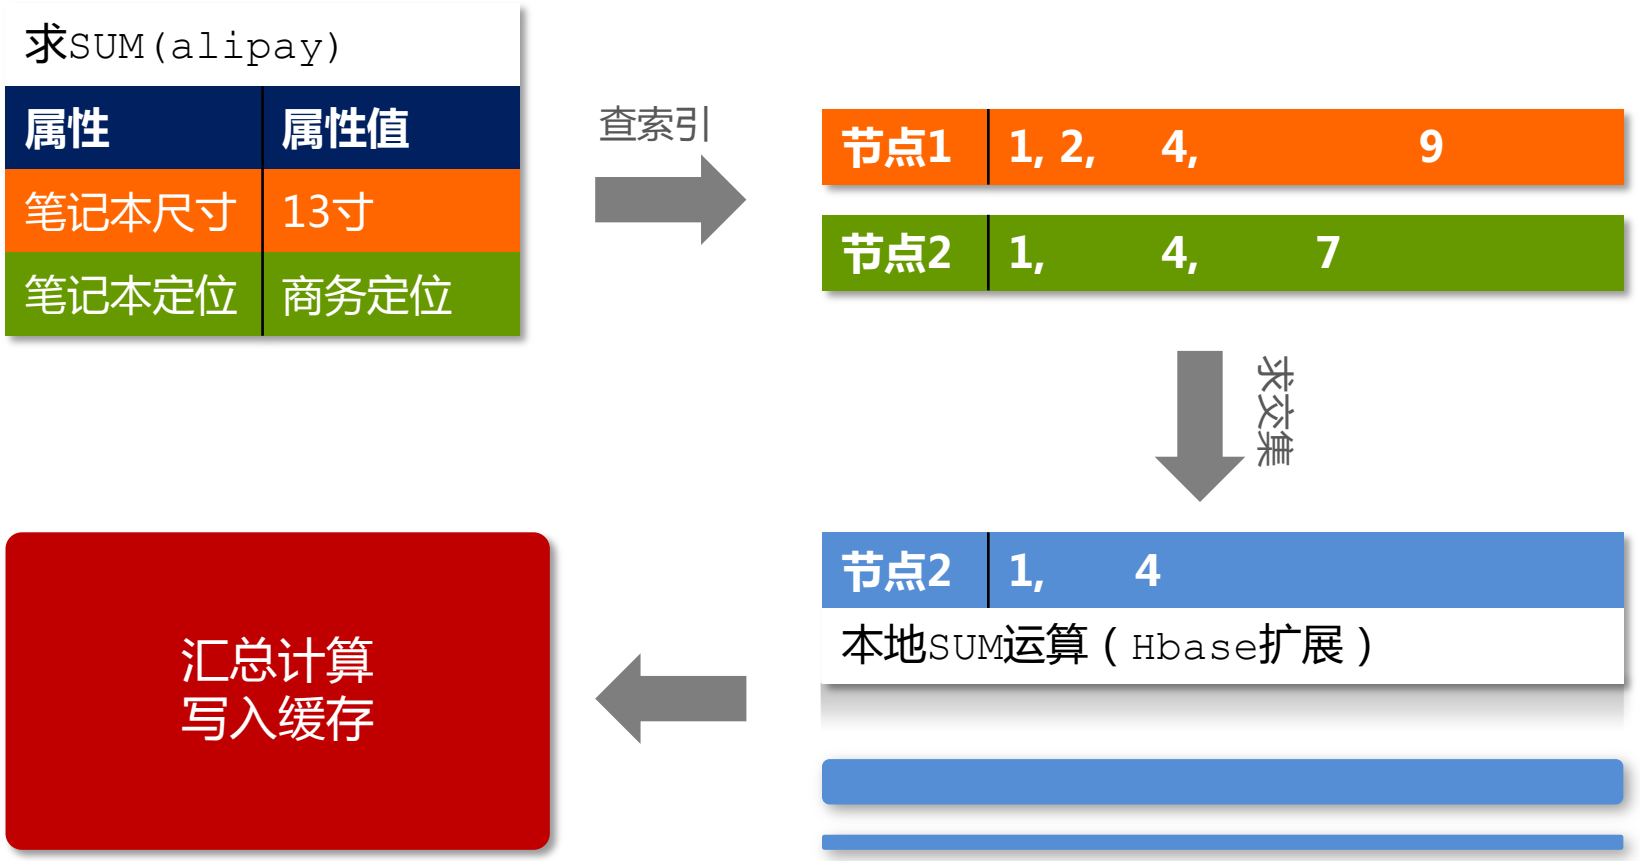

Prom—小结

- 历史数据的实时计算
- 通用性强，支持sum, count, avg, group by, sort
- 空间换时间
  - 变大量随机读为顺序读
  - 避免明细数据网络传输

SQL与NoSQL

- 互为补充，适用场景不同
- SQL
  - 应用开发更简单
  - 支持跨行跨表事务
  - 运维更成熟
- NoSQL
  - 水平扩展性更好
  - 更适合解决海量数据存储与计算

统一的数据中间层—Glider

- 统一数据出口
  - 类SQL
  - HTTP REST
  - JSON返回
- 前后端解耦
- 数据缓存管理

Glider架构

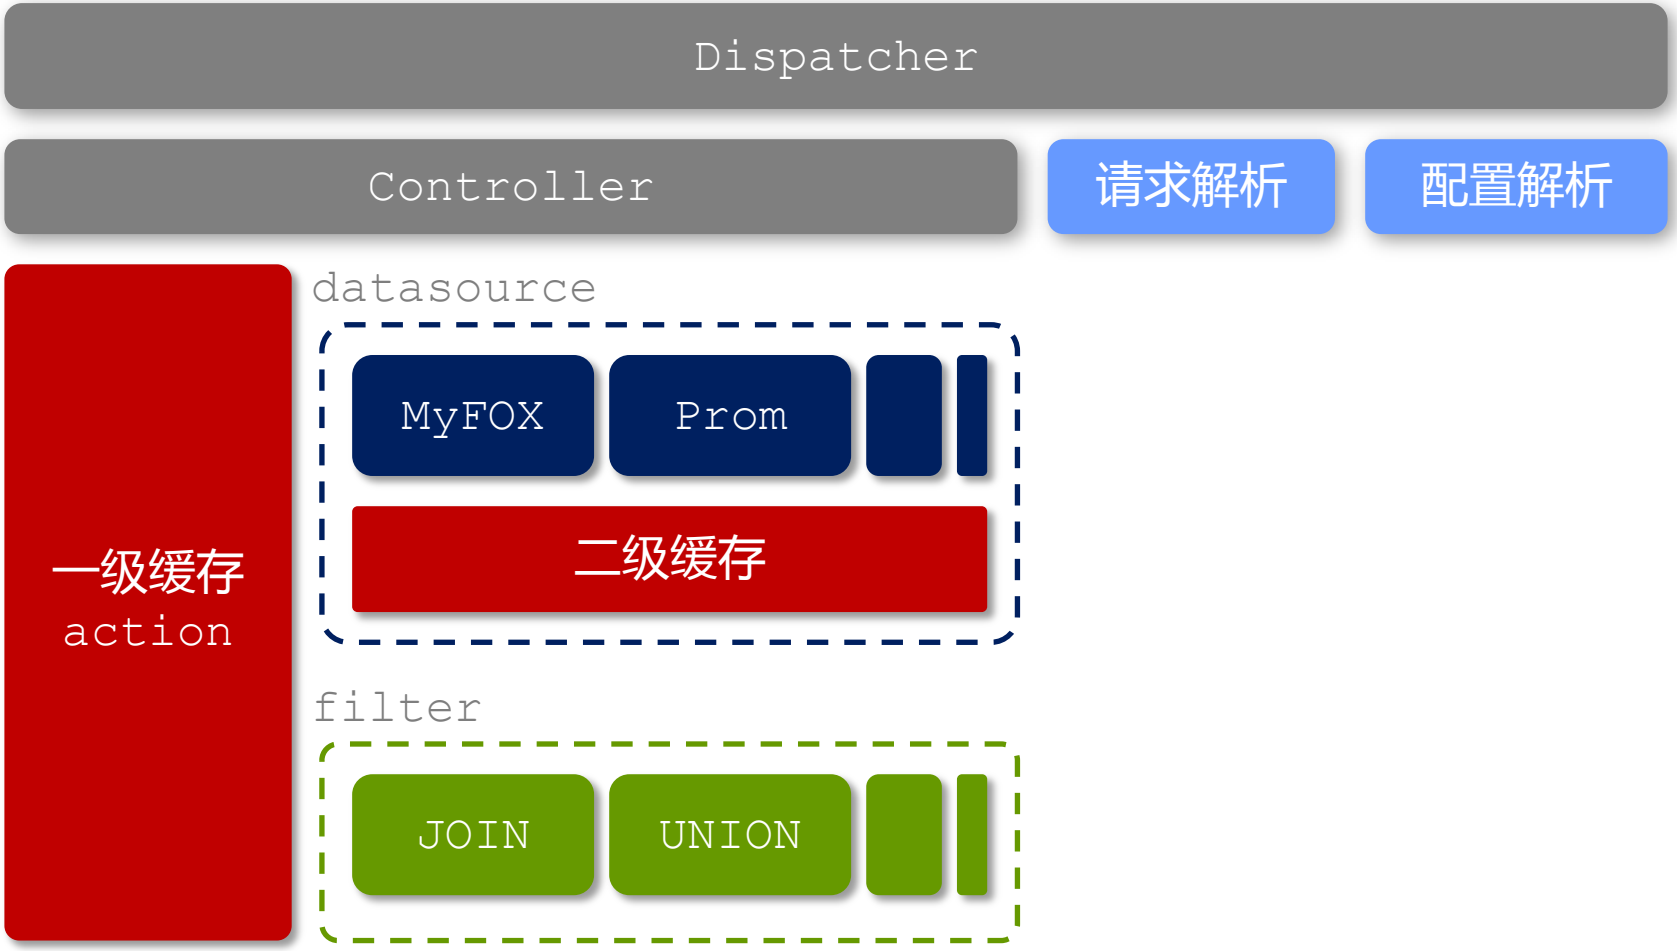
Dispatcher
Controller
请求解析
配置解析
一级缓存
action
datasource
MyFOX
Prom
二级缓存
filter
JOIN
UNION

Glider缓存管理

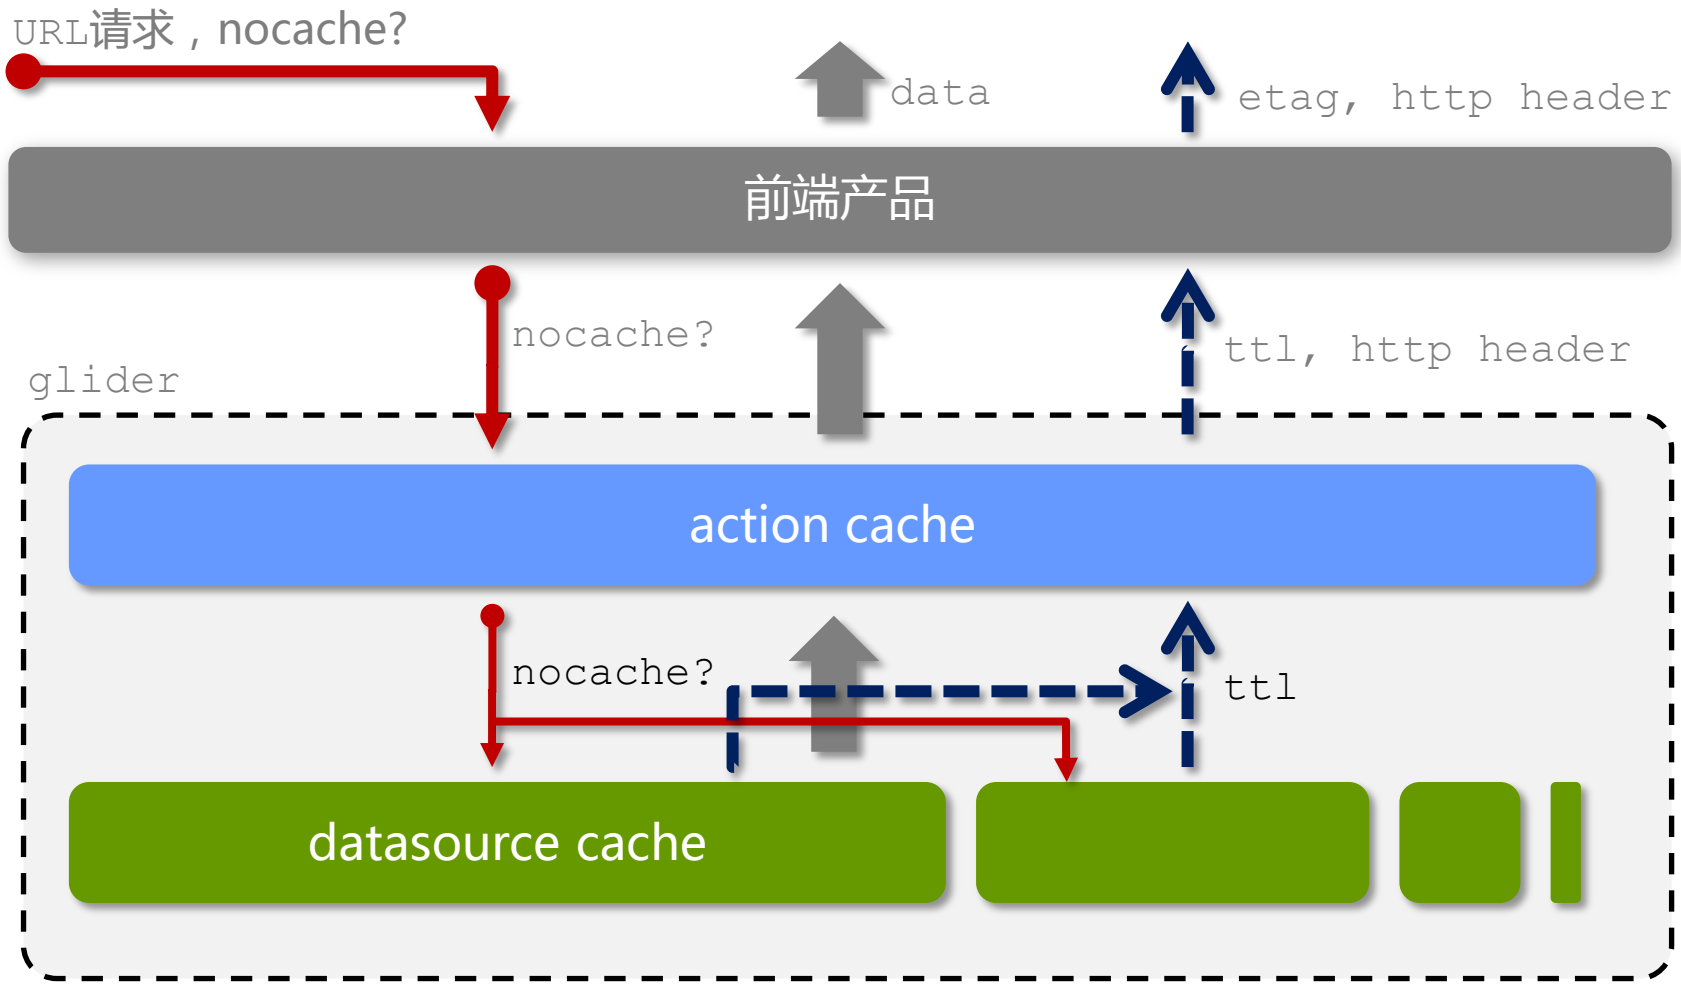
URL请求，nocache?
data
etag, http header
前端产品
nocache?
ttl, http header
glider
action cache
nocache?
ttl
datasource cache

Glider—小结

- 用中间层隔离前后端
  - 底层架构对前端透明
  - 水平可扩展性
- 缓存是把双刃剑
  - 降低后端存储压力
  - 数据一致性问题

通用数据报表框架—Cubex

- 通过配置生成报表，快速开发
- 与组件化、事件驱动的JS框架集成
  - 基础服务封装：http, event
  - 可复用的组件库
  - 统一的组件生命周期管理，易于维护

前端JS框架

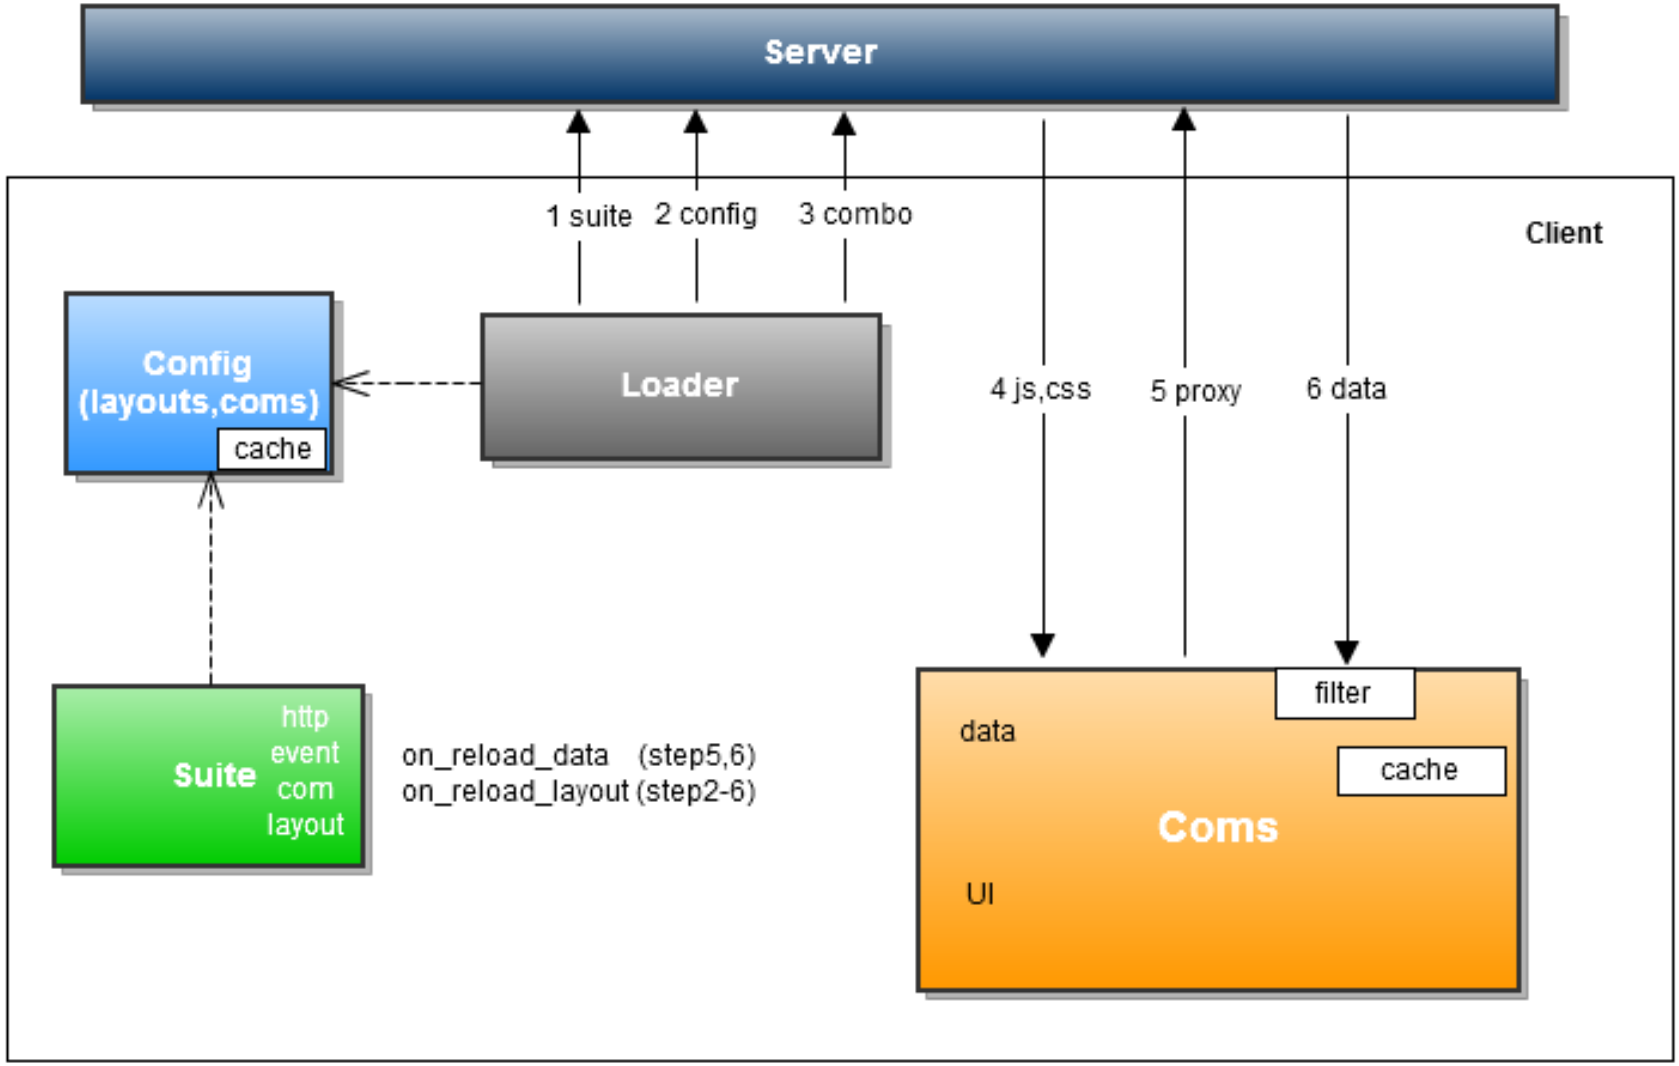
Server
1 suite
2 config
3 combo
Client
Config
(layouts,coms)
cache
Loader
4 js,css
5 proxy
6 data
filter
data
cache
Coms
UI
Suite
http
event
com
layout
on_reload_data (step5,6)
on_reload_layout (step2-6)

回顾

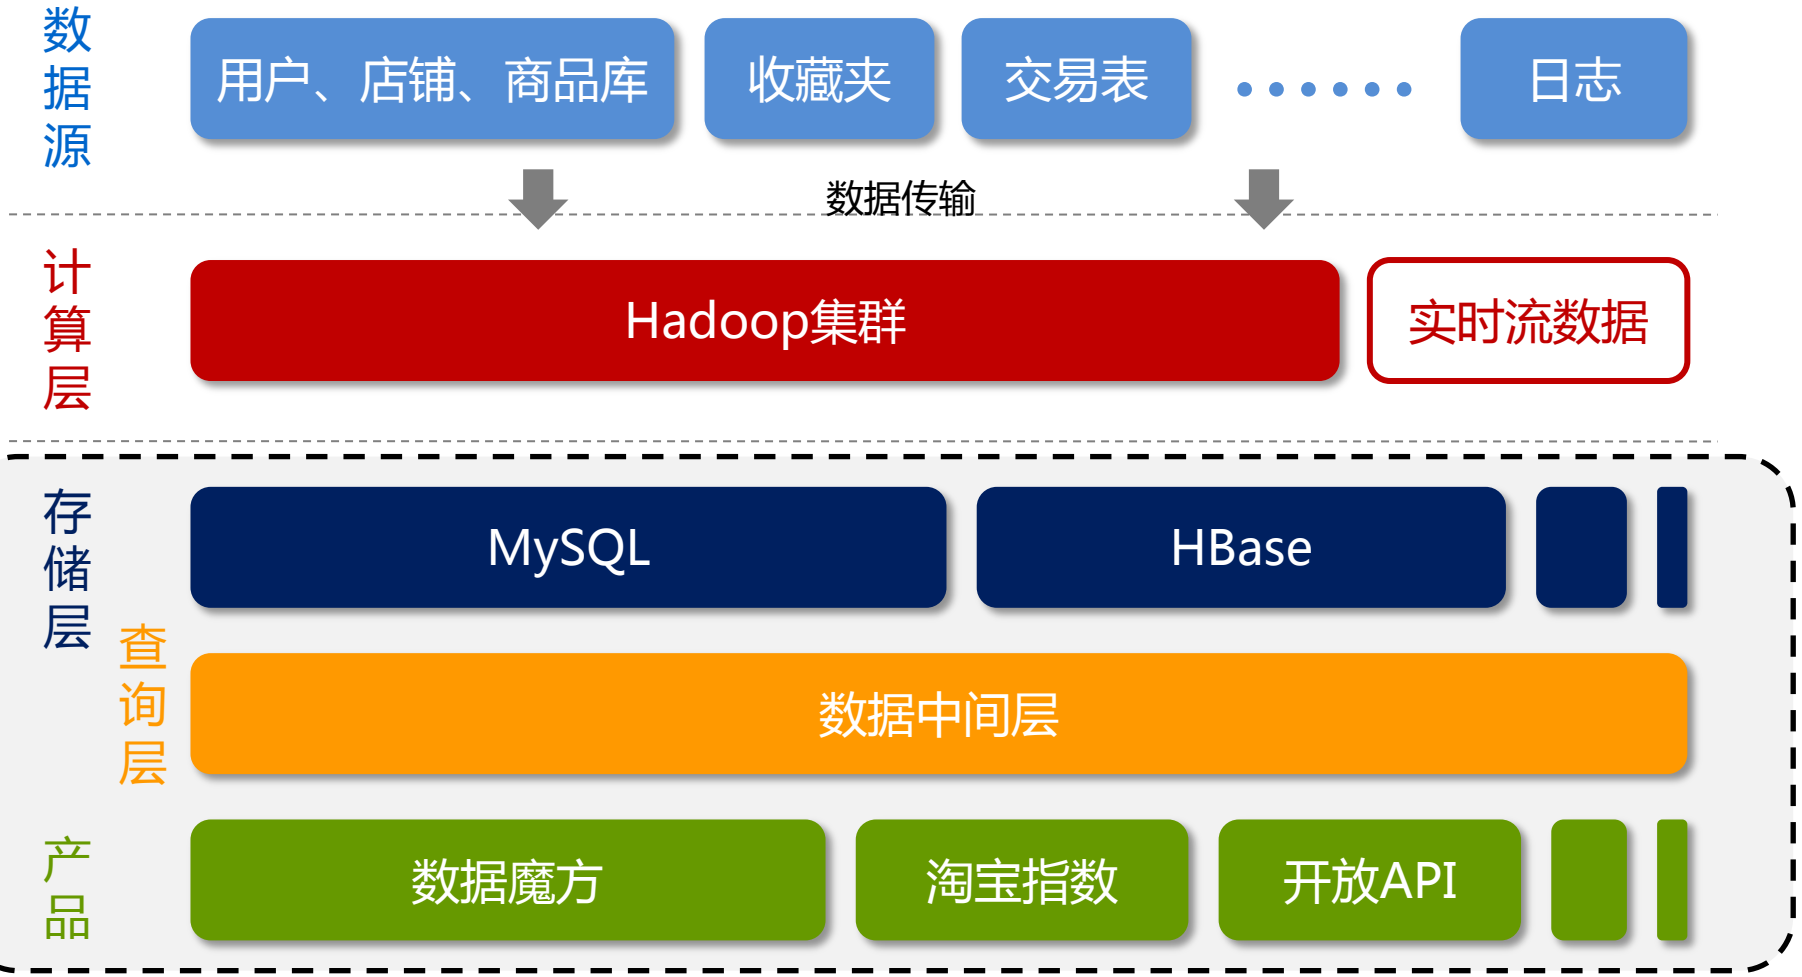
数据源
用户、店铺、商品库
收藏夹
交易表
.....
日志
数据传输
计算层
Hadoop集群
实时流数据
存储层
MySQL
HBase
查询层
数据中间层
产品
数据魔方
淘宝指数
开放API

谢谢!