大规模社区存储构建-贴吧的实践

李瀚

互联网公司技术架构系列资料

由  为您悉心整理

快简历

KuaiJianLi.com

/* 让工作重新关于成长和成就、关于快乐和分享、关于梦想和荣光 */

什么是贴吧

- ✓ 大型综合社区
  - 讨论区+视频区+相册区+游戏区+ itieba+无线贴吧+..
- ✓ 技术
  - 前端+lamp+nosql+数据挖掘+反作弊+无线+..

贴吧面对的技术挑战

- ✓ 数据量
  - 百亿贴子的存储，某些热门主题可达千万回复
  - P级的视频数据存储
  - 来自浏览器每秒10w量级的浏览请求数
  - 内部每秒数十w量级的更新请求转发
- ✓ 可用性&数据安全性
  - 7*24小时的互联网服务，容灾，冗余
- ✓ 快速开发
  - 快鱼吃慢鱼
- ✓ 丰富的应用类型，迥异的访问模式
  - 数百个服务
  - 不同应用有不同要求：检索，推送

贴吧的存储架构解决方案

- ✓ 轻量型解决方案
- ✓ 大数据存储解决方案
- ✓ 服务集群管理方案

贴吧的存储架构解决方案

轻量型解决方案

cover大部分日常快速开发需求

轻量型解决方案

- ✓ Mysql+cache+flash
  - – Mysql：持久化
  - – Cache：加速
  - – Flash：硬件scale up
- ✓ 目标
  - – 解决80%的日常产品开发需求

Mysql-单机

- ✓ 引擎选择
- ✓ 引擎优化
- ✓ 访问模式设计
- ✓ 表设计
- ✓ 性能
  - 一般几百qps到几千qps不等
  - 数据量<1T

Mysql-分布式

- ✓ 问题
  - 横向扩展问题
  - Mysql实例增多，运维问题
- ✓ 解决方案
  - 统一接入
  - 读写分离
  - 主从屏蔽

Cache-加速

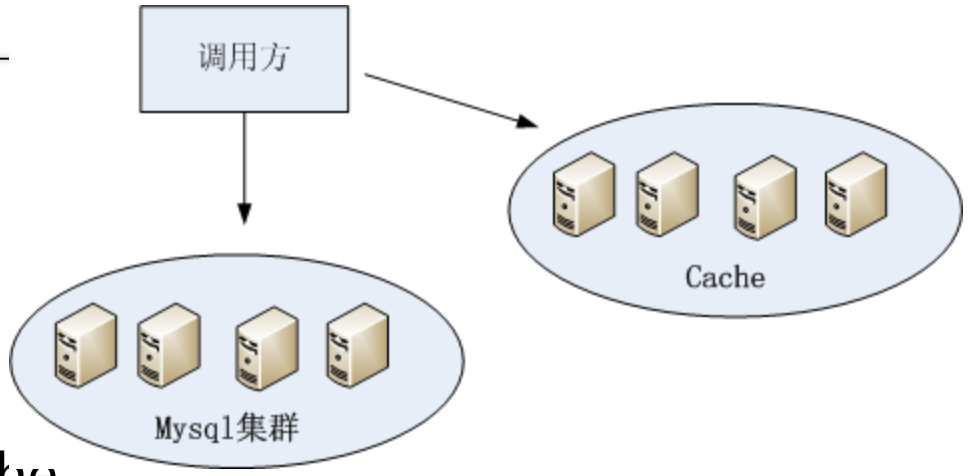

- ✓ Cache的性能
  - 5-10w qps，瓶颈在网卡
  - 2-8法则
- ✓ Cache的种类
  - 页面级cache vs 单条数据的cache
    - Ex: 贴子内容页 vs 贴吧图片页
- ✓ 设计难点：cache更新
- ✓ 局限性
  - 只解决浏览瓶颈，不解决更新瓶颈

Flash卡

- ✓ Flash卡：天下有免费的午餐
  - 随机读写性能比磁盘有量级上的提升
- ✓ 缺点
  - 存储空间

参考资料

轻量型社区存储：mysql+cache+flash

- ✓ 适用场景：常规需求
  - 单机数据量几百G量级
  - 流量亿量级
- ✓ 优点
  - 开发灵活快速
  - 维护成本低
- ✓ 缺点
  - 通用存储，性能受限

大数据存储解决方案

Cover某些特定的大数据量产品需求

分区

- ✓ 分区概念
  - 垂直分区：按功能
  - 水平分区：按key
- ✓ 分区的目的
  - 冗余
  - 可扩展性
  - 性能：将不同的访问模式分开，利于优化

分区-消息队列(MQ)

- ✓ 分区的实现：消息队列
- ✓ 消息队列
  - Replication
  - 可靠性：
- ✓ 贴吧的消息队列集群
  - 峰值数十w/s的转发量

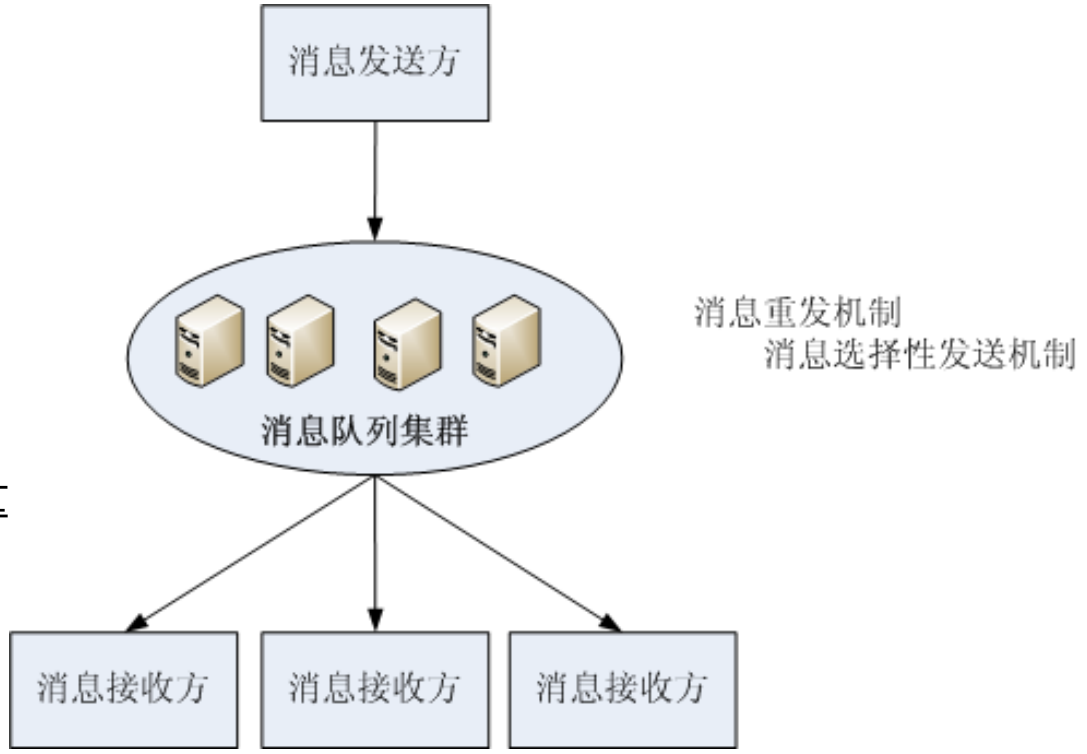

贴吧贴子存储

- ✓ 数据规模
  - – 数十亿主题，百亿量级的贴子
  - – 热门主题支持1000w回复
- ✓ Mysql is impossible！

贴吧贴子存储

- ✓ 设计思路
  - 分区
    - 主题列表页和贴子列表页存储分离
    - 关系存储和内容存储分离
    - 水平分区

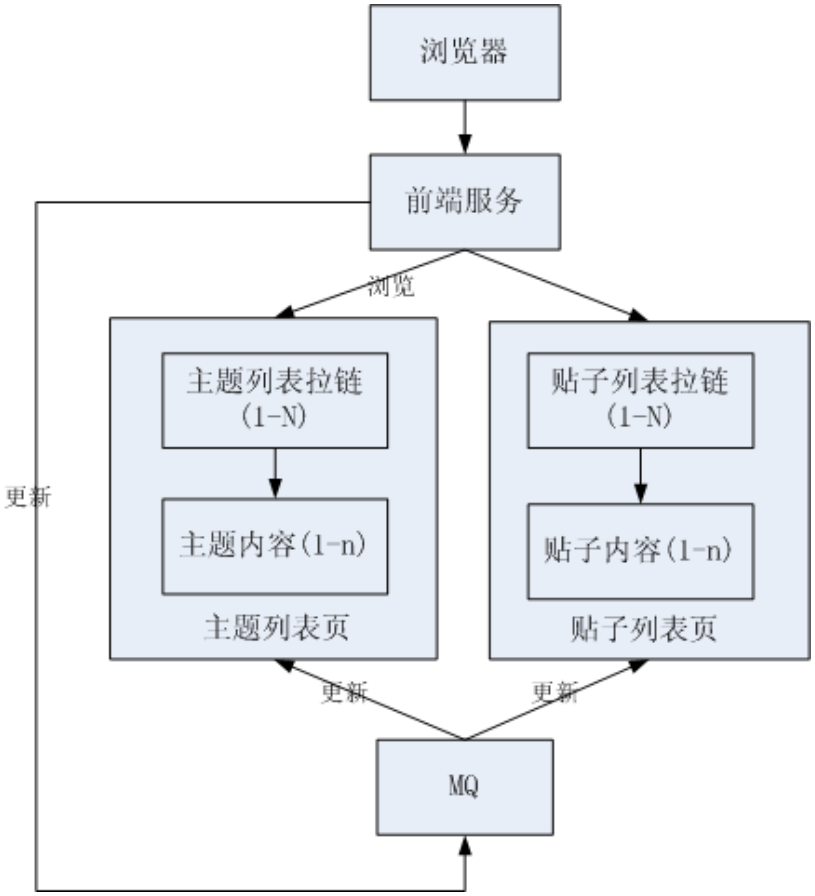

贴吧贴子存储

- ✓ 性能
  - 随机存储和连续存储
  - 内存patch
  - 多种cache
- ✓ 单机数据安全性
  - Binlog
- ✓ 整体数据安全性
  - 消息队列
- ✓ 效果
  - 单机可以跑满网卡

Key-value存储

- ✓ 视频存储
  - – 查询模式：
    - – 视频id->视频流
  - – 数据量P量级
  - – 典型的KV存储
- ✓ 单机kv设计考虑
  - – 数据安全性
  - – 可和外围cache配合使用
- ✓ 分布式kv

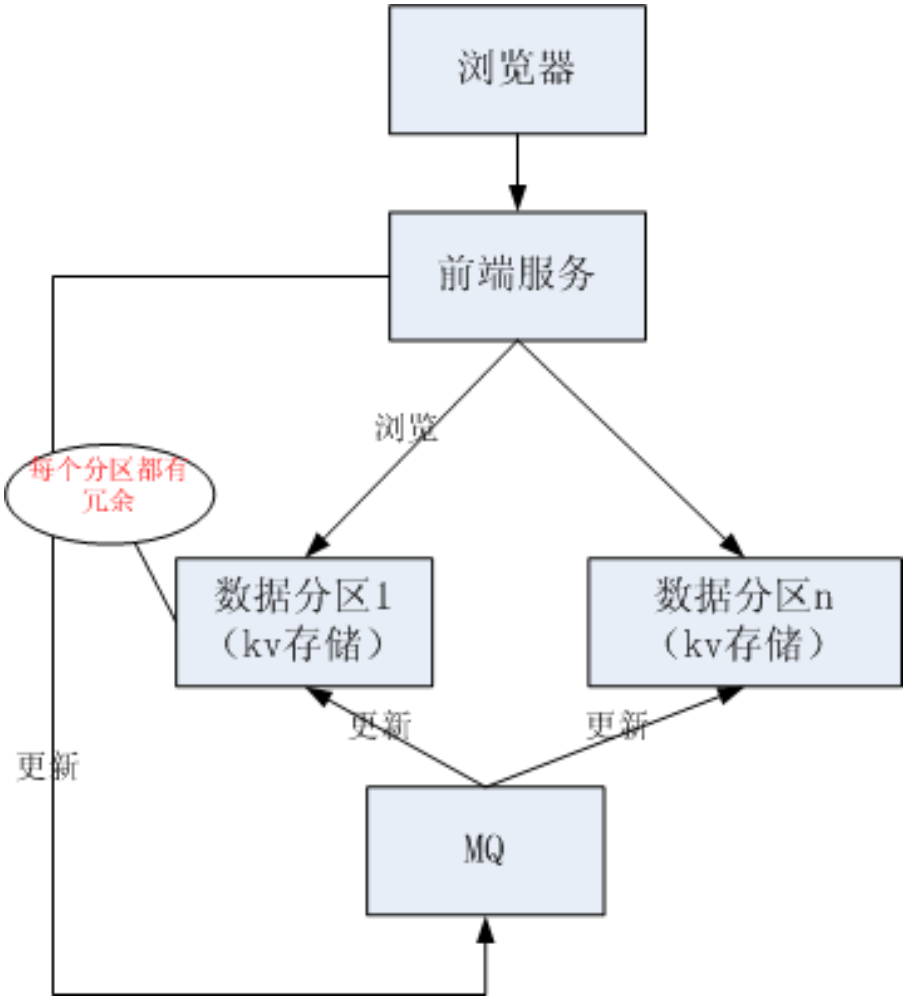

Key-value存储

- ✓ 优点
  - 模式简单，易于分片
  - 采用追加写，更新性能有保证
- ✓ 缺点
  - 不支持关系查询
  - 开发成本

大数据量存储解决方案

- ✓ 适用场合
  - 某些数据量特别大或者对性能要求特别苛刻的应用
  - 某些需要特殊功能的需求
- ✓ 优点
  - 专用存储，性能可以极限优化
- ✓ 缺点
  - 开发维护代价较高
  - 灵活性偏弱

- ✓ 更多的例子：检索，推送，日志分析等

服务集群管理方案

解决机器和服务数量增多带来的管理问题

Baidu 百度

负载均衡

- ✓ 面向的问题
  - 服务故障
  - 蝴蝶效应
  - 数据迁移
  - 机器差异
  - 等等

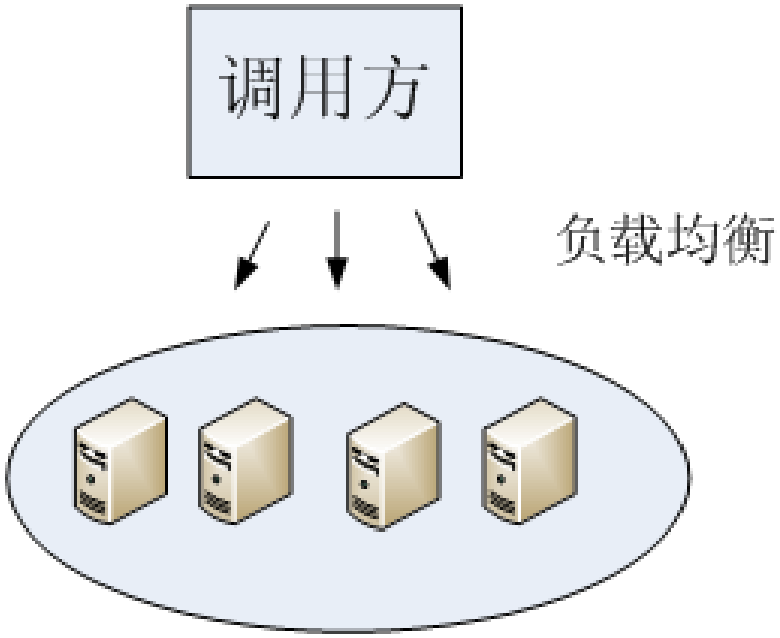

负载均衡

- ✓ 参考文章

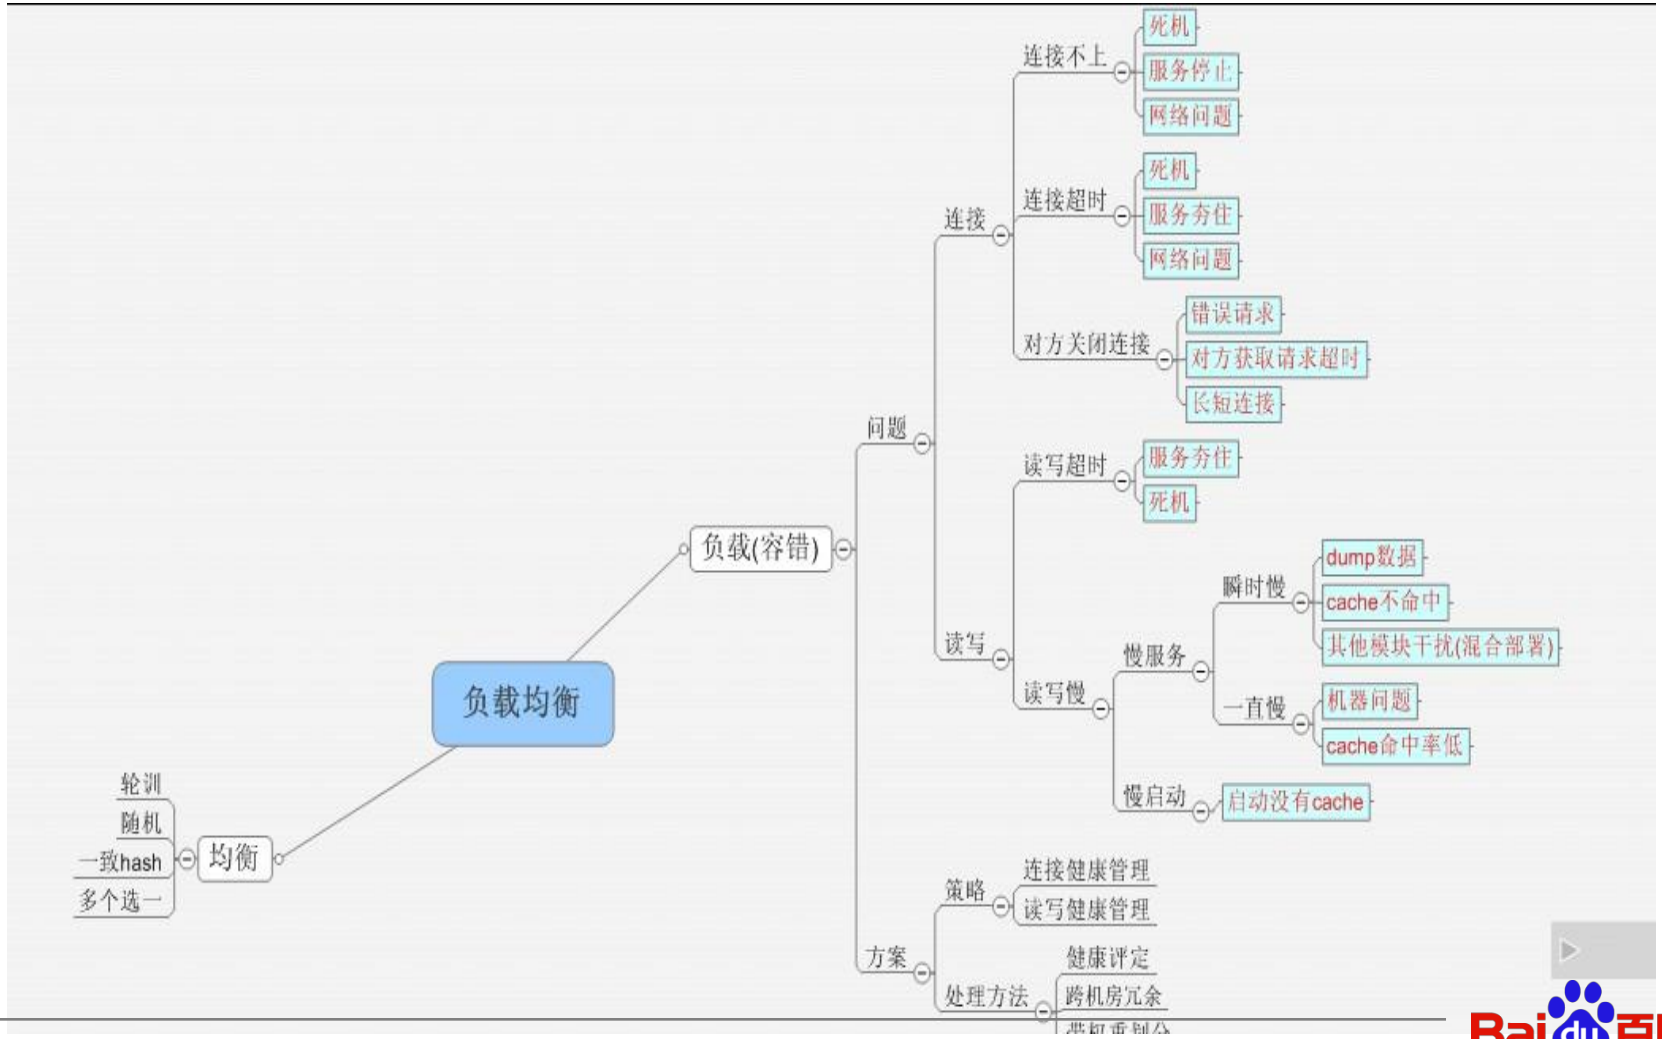
负载均衡
负载(容错)
问题
连接
连接不上
死机
服务停止
网络问题
连接超时
死机
服务夯住
网络问题
对方关闭连接
错误请求
对方获取请求超时
长短连接
读写
读写超时
服务夯住
死机
读写慢
慢服务
瞬时慢
dump数据
cache不命中
其他模块干扰(混合部署)
一直慢
机器问题
cache命中率低
慢启动
启动没有cache
方案
策略
连接健康管理
读写健康管理
处理方法
健康评定
跨机房冗余
均衡
轮训
随机
一致hash
多个选一

资源定位

- ✓ 服务数量扩大带来的问题
- ✓ 资源定位
  - 资源中心：服务元信息存储
  - 资源发现
  - 资源路由

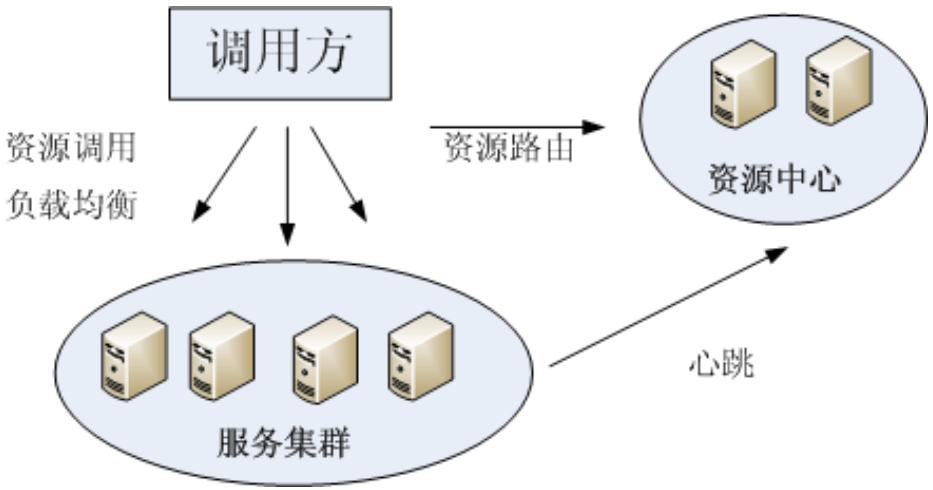

- ✓ 设计思路
  - 心跳机制
  - 资源中心的单点问题和性能问题

大规模社区存储方案

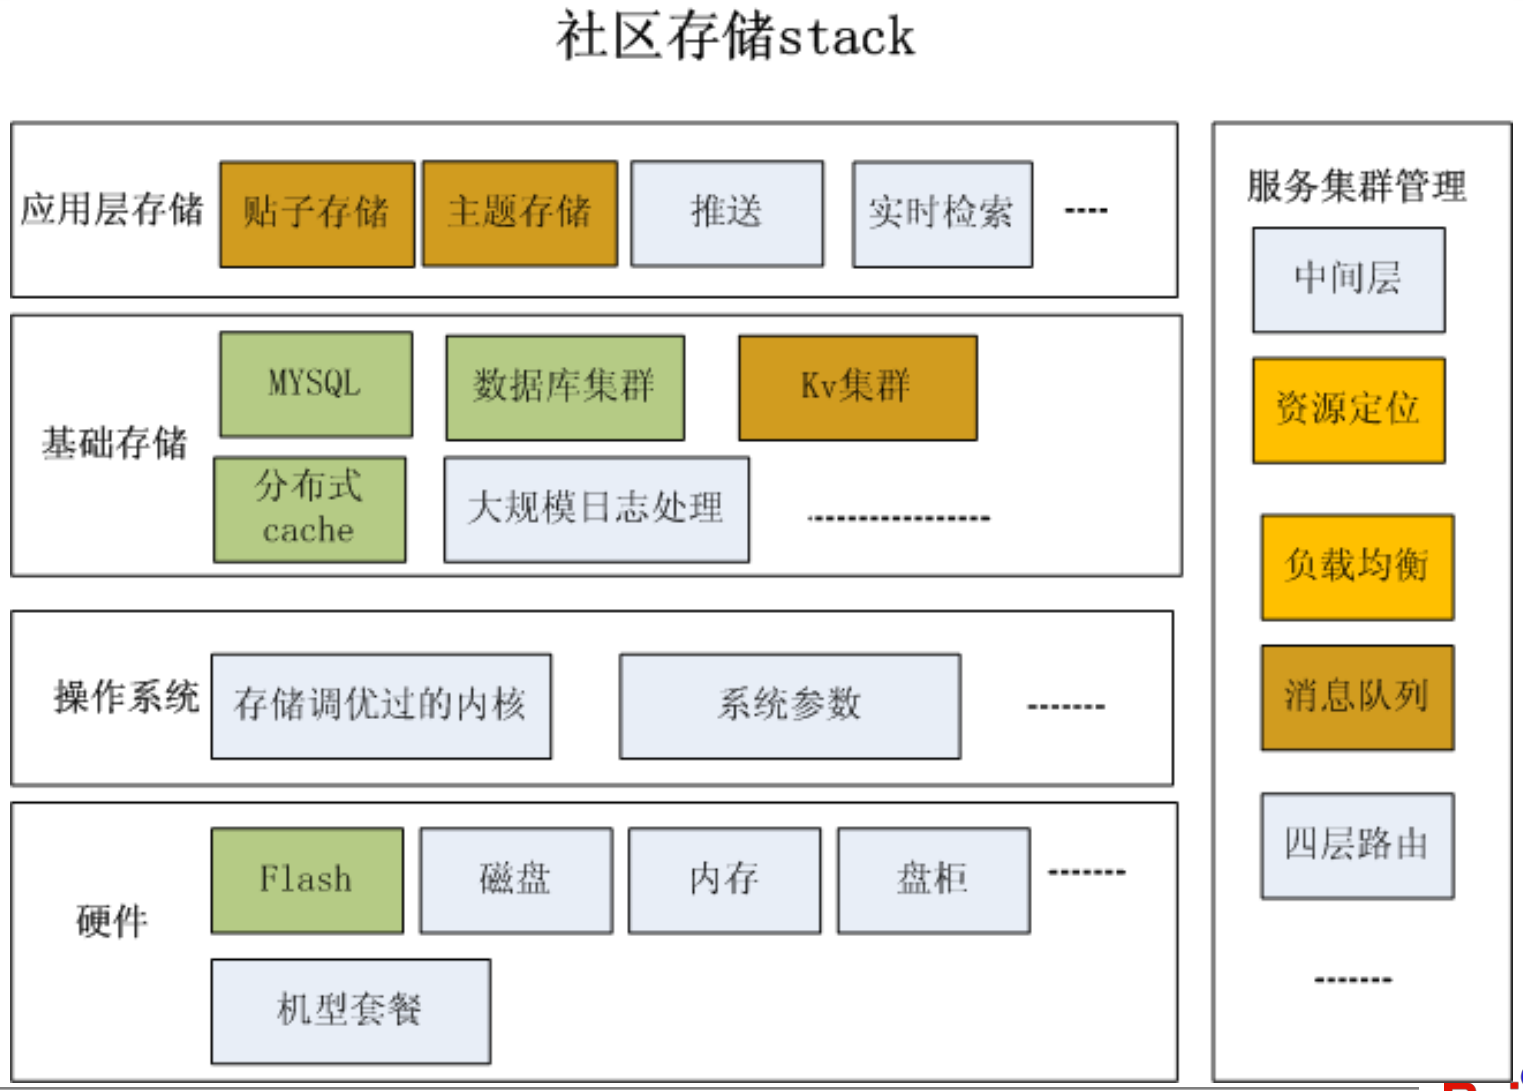

- ✓ 贴吧技术blog
- ✓ 诚邀各路英才加盟，这里提供全面的社区技术实践机会

FAQ